



האוניברסיטה העברית בירושלים
THE HEBREW UNIVERSITY OF JERUSALEM

קורס SLAM ניווט מוידאו 67604 – תרגיל 7

דור מסיקה, ת.ז. 318391877
רון קוברובסקי, ת.ז. 322875907

קישור לגיט של התרגיל:

https://github.com/Dor890/SLAM/blob/main/VAN_ex/code/Ex7/ex7.py

1. זיהוי מועמדים ל-Loop Closure. א. Relative Covariance – נמצא את המרחק הקצר ביותר בין c_n ל- c_i ונסכום את ה-covariances לאורך המסלול כדי לשערך את ה-covariance היחסי $\Sigma_{(n|i)}$.

מה יהיו בחירות הגיוניות עבור המשקל על הצלעות?

נרצה לחשב את המסלול הקצר ביותר בין שני קודקודים בגרף על פי ה-convariances היחסיים ביניהם, אבל הרי מדובר במטריצה בגודל 6 על 6. לכן, בחירות הגיוניות עבור משקל הצלעות יכולות להיות דטרמיננטה, trace, נורמת פובניוס וכו', או מגוון נורמות אחרות אשר בסופו של דבר לוקחות את המטריצה והופכות אותה לסקלאר.

במה אנחנו בחרנו להשתמש?

אנחנו בחרנו להשתמש בדטרמיננטה, על מנת לתת את המשקל היחסי על פי שטח המטריצות, שכן בעצם נוכל לומר ש-covariance קטן מתאפיין בכך ששטח האליפסה הוא קטן, כלומר מידת הוודאות הינה גדולה, ונוכל להסתכל על המלבן המכיל את האליפסה הזו ולומר ששטחו מהווה קירוב טוב לשטח האליפסה (עד כדי קבוע).

איך מימשתם את אלגוריתם המסלול הקצר ביותר?

השתמשנו בספריה dijkstar, המממשת את אלגוריתם Dijkstra. תחילת יצרנו גרף שבו כל קודקוד הוא keyframe במסלול, ולאחר מכן יצרנו צלעות ישירות בין כל שני keyframes סמוכים. עבור כל צלע קבענו את המשקולת להיות הדרמיננטה של ה-relative covariance בין שניהם, והפעלת האלגוריתם באופן זה החזירה לנו את המסלול המינימלי בין שני קודקודים מסוימים.

- ב. בחרנו את המועמדים המתאימים ביותר להיות קרובים ל- c_n pose על ידי הפעלת מרחק מהלנוביס, ואז השתמשנו בערך סף של 50 על מנת לקבוע אם מועמד ממשיך לשלב הבא.

2. נבצע Consensus Matching לפריימים המועמדים, ונקבע ערך סף עבור מספר ה-inliers אשר מעידים על התאמה מוצלחת להיות 75.

3. נשתמש בהתאמות הללו שמצאנו על מנת לבצע Bundle optimization קטן, כדי לחלץ את ה-Relative pose ו-Covariance של שני פריימים.

מה יהיה ערך ראשוני הגיוני עבור הבאנדל?

הערכים הראשוניים עבור ה-poses של כל keyframe בכל באנדלון חדש שאנו יוצרים יהיו הערכים המאופטמים אותם חישבנו כבר בתרגיל 5, ובעזרתם נוכל לחשב את ה-pose היחסי ביניהם.

כיצד חילצתם את ה-covariance המתאים?

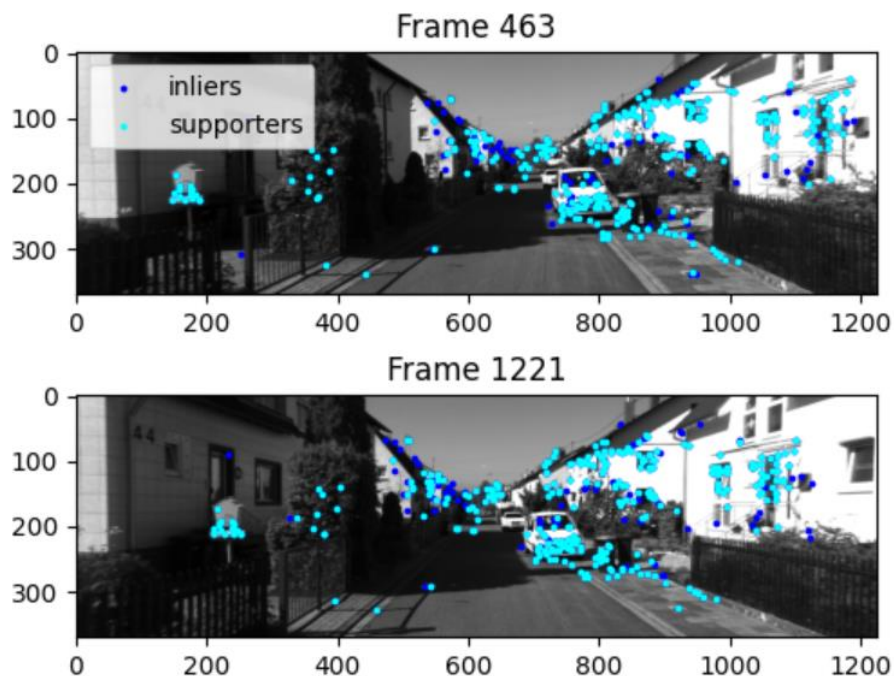
על מנת לחלץ את ה-covariance היחסי המתאים בכל באנדלון נבצע את אותו תהליך שביצענו בתרגיל 6, כאשר אנו לוקחים את 2 מיקומי המצלמות, מחשבים את מטריצת האינפורמציה, מבצעים conditioning על ה-keyframe השני ומחשבים inverse.

4. נעדכן את ה-Pose graph על ידי הוספת המדידות ואיפוטומו על מנת לעדכן את המסלול המשוער.

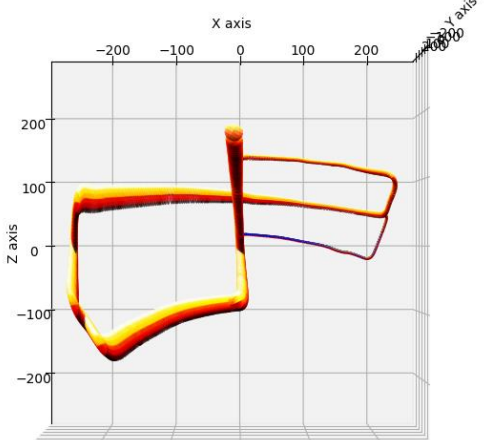
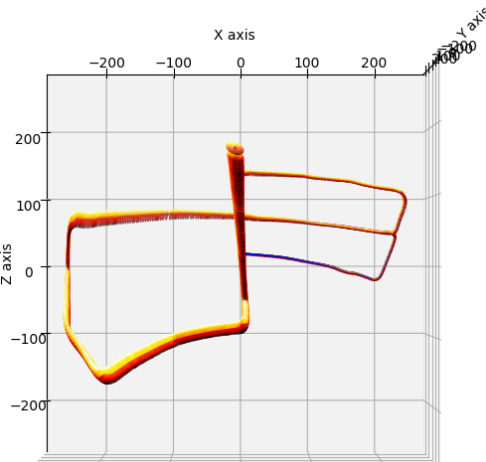
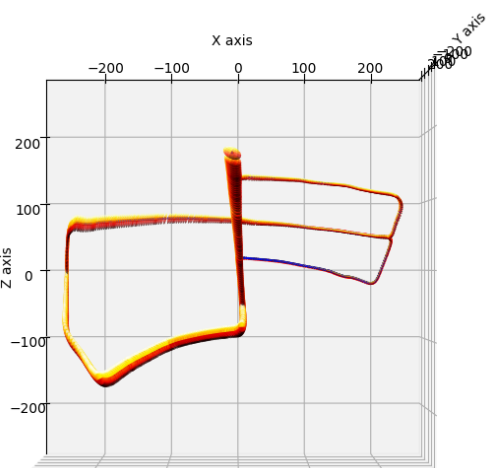
5. כמה לופים מוצלחים זיהינו? 160.

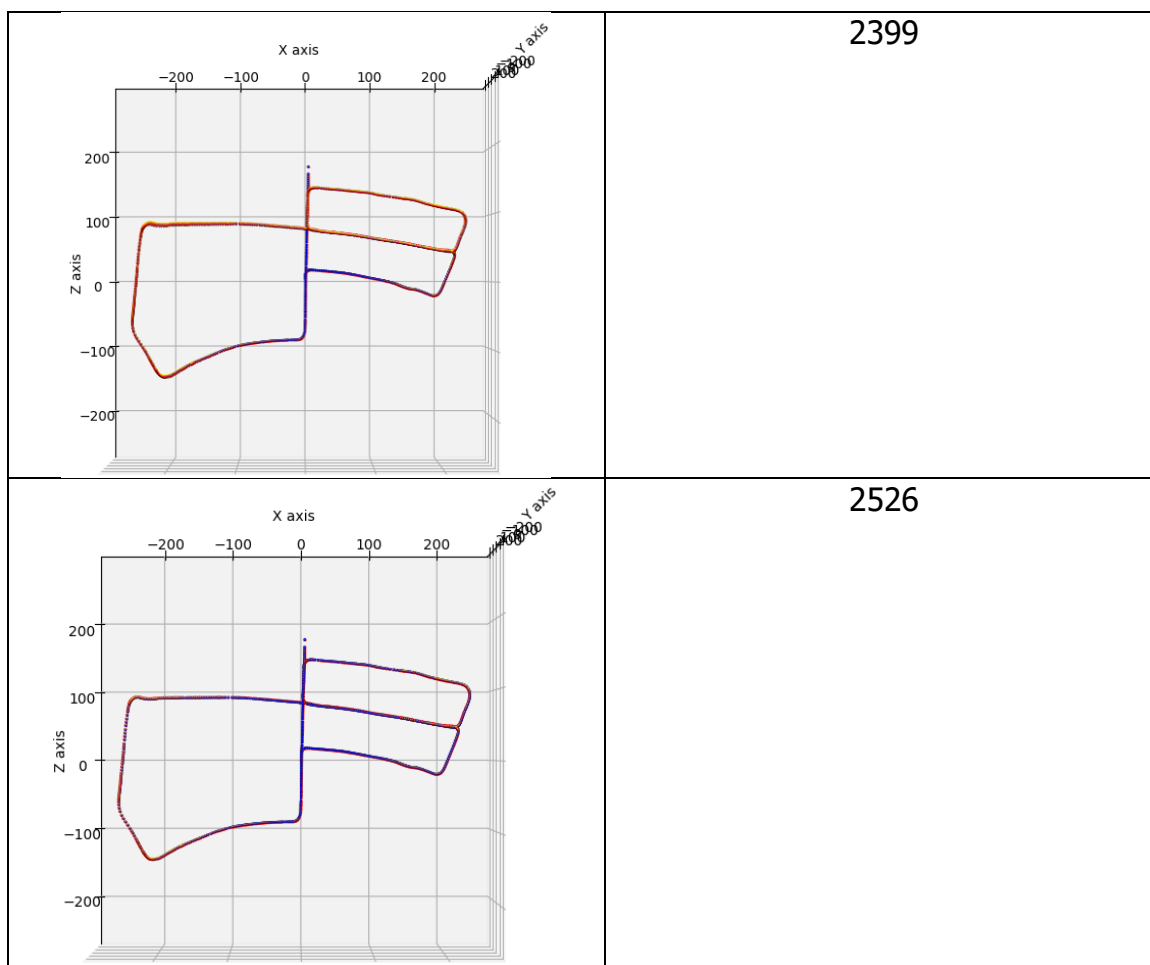
נציג את תוצאת ההתאמות עבור consensus match מוצלח כלשהו (עבור התמונות השמאליות, inliers ו-outliers בצבעים שונים).

Left0 and Left1 matches & supporters
Number of supporters: 294, 80.99%



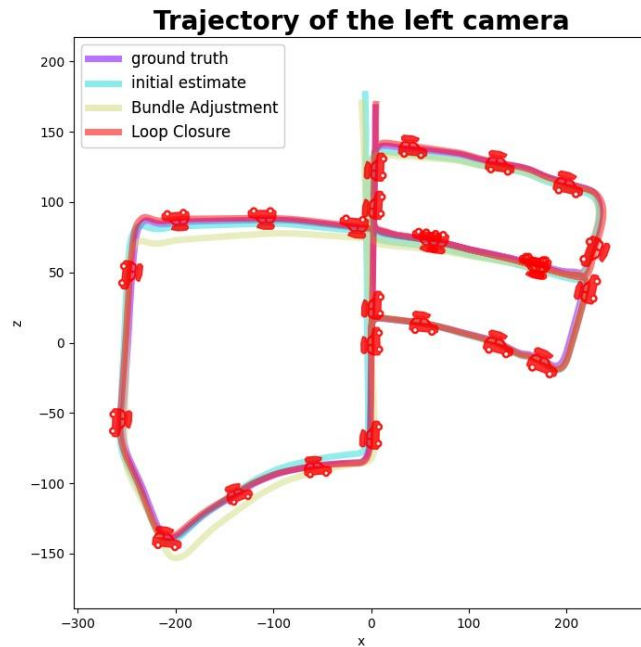
נבחר 5 גרסאות של pose graph לאורך התהליך ונציג אותם (כולל location covariance). נסביר באילו זמנים בחרנו להציג את הגרפים.

מסלול	מספר פריים
	1213
	1230
	1426

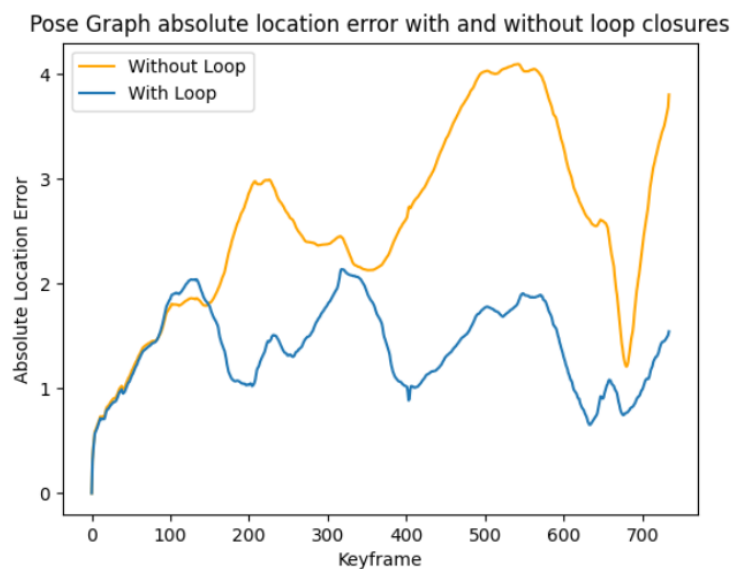


בחרנו להציג את הגרפים בנקודות הקצה של הקטעים בהם זהו Loops. לדוגמה, פריים מספר 1213 נמצא בתחילת הקטע הראשון שאנו חוזרים עליו (נקרא לו "הלופ הראשון", במסלול המרכזי בצד ימין), בו אנו מקבלים מסלול זהה לזה שקיבלנו בתרגיל הקודם. ניתן לראות שמהר מאוד, כבר 17 פריימים אחריו בפריים 1230, רמת הודאות עלתה משמעותית ולא השתנתה כמעט עד לפריים 1426, סוף הקטע של הלופ הראשון. "הלופ השני", בו אנו חוזרים אל הנקודה בה התחלנו את המסלול ומתמשכת עד המקום בו הרכב פנה ימין, מסתיים באזור פריים 2399, ו"הלופ השלישי" בקצהו העליון של המסלול הינו בפריים 2526. ניתן לראות איך בכל זיהוי של לופ רמת הודאות של שיערוך המסלול עולה באופן משמעותי בכל אזורי המסלול.

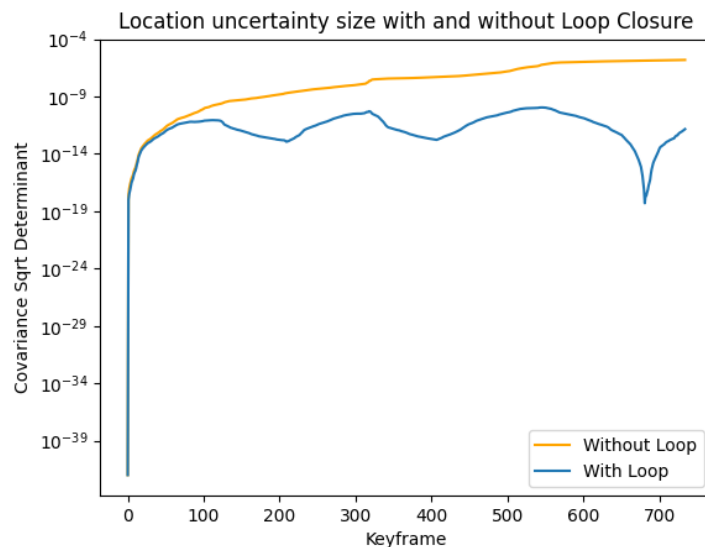
נציג את מיקומי ה-Pose Graph עם ה-ground truth והן עם loop closures ובלוי.



נציג גרף עם ה-absolute location error עבור כל ה-Pose Graph עם ובלי ה-loop closures.



נציג גרף עם גודל ה- $\text{location uncertainty}$ עבור כל ה- Pose Graph עם ובלי ה- loop closures , ונציין איזה אומדן של גודל אי הודאות בחרנו.



בחרנו את אומדן גודל אי הודאות להיות השורש של הדטרמיננטה של ה- Relative covariances, בדיוק כפי שחישבנו אותם עבור משקלי הצלעות בגרף. כפי שציינו קודם לכן, גודל זה נותן משקל יחסי על פי שטח המטריצות, ו-covariance קטן מתאפיין בכך ששטח האליפסה הוא קטן, כלומר נוכל לקבל אומדן טוב עבור שטחי האליפסות ועל כן נקבל אומדן טוב עבור מידת אי הודאות הקיימת. נוכל לראות בגרף שבשונה מהמקרה הבסיסי בו חוסר הודאות הלכה וגדלה בכל שלבי ההתקדמות במסלול, ביצוע ה- Loop Closure עוזר לנו לקבל ודאות נוספת במקומות מסוימים בגרף, אשר משפיעים על כולו ותורמים לכך שאי הודאות מתאזנת עבור כל הגרף באזור נמוך יותר, ולא נמצאת במגמת עלייה.